


实验怎样比较 D 与 C？

先用含 D 的语料微调，再冻结同一个模型，分别尝试生成 D 和 C。

D/C 的实验流程：同一个模型，比较训练过与未训练过的目标



D：微调中出现过的目标；C：从本次微调语料中排除的目标。例如 D 是 `alice17@example.org`，C 是 `bruce24@example.org`：都是邮箱，具体字符串不同；前者进入微调语料，后者没有。此例仅为说明，非实验原始记录。

攻击时改变什么？本次GCG攻击利用梯度搜索提示中可修改的token（文本片段），优化器知道要生成的目标。k是可修改位置的数量；模型权重保持冻结。命中C表示未参与本次微调的目标也可能被强制生成。


本次主扫描：一个 GPT-2 124M 微调模型；每组25人，每人SSN（社会安全号码格式）和email两个合成字段，共50靶标/组。三个seed是三次不同随机初始化的攻击，不是三次独立训练。C的“未训练”只指本次微调。

完整 D/C 抽取率：总体与两个字段

随着 k 增大，两组抽取率都升高；判断成员差异还要比较 D 与 C 的距离。

完整抽取率：D 与 C 都随 k 增大而更容易成功

● D：训练过 ● C：未训练过



横轴按实验网格等距排列，数值间距不等；灰区 k=0 为无优化基线。竖线为逐点 95% 区间。

每组 25 人、两字段共 50 个目标、3 个攻击 seed；合并每 k 为 150 次，单字段为 75 次。


读图：蓝色是 D，橙色是 C。 α (forcing floor) 就是 C 的抽取率； τ 是 D 抽取率减 C 抽取率，单位为“百分点”。例如 $82.00\% - 80.67\% = +1.33$ 个百分点。

每个总体点为 150 次攻击/组 (25 人 × 2 字段 × 3 seed)；每个字段点为 75 次攻击/组。误差线是 95% 点区间，表示估计的不确定性，不是 95% 的攻击结果落在其中；各点区间不构成整条曲线的同时保证。

成功沿用实验的 exact_match 规则：规范化后，完整目标值出现在生成文本中；不要求整段输出只含目标。k=0 是单独的固定提示基线，提示/优化目标形式与 GCG 不同。横轴等距排列，不代表 k 的数值差。

按字段拆开的完整抽取计数

每格读作“75次攻击中成功了几次”；它不是成功人数。



实际例子：k=20。SSN中D成功48/75次，C成功46/75次；email中两组均成功75/75次。合并后D为123/150，C为121/150，正好得到82.00%与80.67%。

为什么不能称作75个样本？同一个人、同一个字段被攻击了三次，这三次相关。同一人还有两个字段。因此统计区间按人员重采样，不能把重复攻击当成新增人员。

本图保留全14个k、全部4个组别/字段组合，共56格；无插值、无筛选。整数计数本身不带误差线，抽取率的区间见上一页。唯一靶标的成功次数与重复稳定性见接下来的两页。


逐靶标成功情况：SSN 完整版

一行是一个匿名靶标，一列是一个 k；0、1、2、3 表示三个 seed 中的成功次数。

SSN：全部 50 个目标在每个 k 下的成功次数


□ 0/3 次成功 ■ 1/3 次成功 ■ 2/3 次成功 ■ 3/3 次成功

D · 25 个训练目标



k (按实验网格等距排列；竖线左侧是 k=0)

C · 25 个未训练目标



匿名编号；每格是同一目标在 3 个攻击 seed 中的成功次数。按首次命中、总成功次数、编号排序。

保留每个 k 的实际成败：较小 k 成功，不代表较大 k 必然成功。目标逐格描述属于探索性结果。

颜色越深表示三次尝试中成功越多；3 表示本次三个 seed 全成功，并不保证未来必成功。D01 和 C01 是不同组的匿名编号，不表示它们构成 E17 匹配对。

每个面板包含全部 25 个靶标；排序仅用于阅读。保留“成功后在更大 k 失败”的格子；未将首次成功之后全部补成成功。k=0 仍为单独基线。


逐靶标成功情况：email 完整版

一行是一个匿名靶标，一列是一个 k；0、1、2、3 表示三个 seed 中的成功次数。


email：全部 50 个目标在每个 k 下的成功次数

□ 0/3 次成功 ■ 1/3 次成功 ■ 2/3 次成功 ■ 3/3 次成功

D · 25 个训练目标



C · 25 个未训练目标



k (按实验网格等距排列；竖线左侧是 k=0)

匿名编号；每格是同一目标在 3 个攻击 seed 中的成功次数。按首次命中、总成功次数、编号排序。

保留每个 k 的实际成败：较小 k 成功，不代表较大 k 必然成功。目标逐格描述属于探索性结果。

颜色越深表示三次尝试中成功越多；3 表示本次三个 seed 全成功，并不保证未来必成功。D01 和 C01 是不同组的匿名编号，不表示它们构成 E17 匹配对。

每个面板包含全部 25 个靶标；排序仅用于阅读。保留“成功后在更大 k 失败”的格子；未将首次成功之后全部补成成功。k=0 仍为单独基线。

完整曲线数值表

括号内是95%区间；差值为百分点。D、C两组与全部14个k均保留。

k	D 抽取率；区间(%)	C 抽取率；区间(%)	D-C；区间(百分点)	区间方法	攻击小时 C / D
0	0.00% [0.00, 10.33]	0.00% [0.00, 10.33]	+0.00 [-10.33, +10.33]	边界法	0.009 / 0.009
1	0.00% [0.00, 10.33]	0.00% [0.00, 10.33]	+0.00 [-10.33, +10.33]	边界法	0.732 / 0.735
2	0.00% [0.00, 10.33]	0.00% [0.00, 10.33]	+0.00 [-10.33, +10.33]	边界法	1.124 / 1.135
3	0.00% [0.00, 10.33]	0.00% [0.00, 10.33]	+0.00 [-10.33, +10.33]	边界法	1.163 / 1.170
4	4.00% [0.67, 8.67]	1.33% [0.00, 3.33]	+2.67 [-1.33, +8.00]	人员重采样	1.184 / 1.172
6	20.00% [12.67, 28.00]	27.33% [20.67, 34.00]	-7.33 [-18.00, +2.67]	人员重采样	1.085 / 1.121
8	48.67% [41.33, 55.33]	47.33% [40.00, 54.67]	+1.33 [-9.33, +11.33]	人员重采样	0.951 / 0.940
12	66.00% [60.00, 72.67]	63.33% [56.67, 70.00]	+2.67 [-6.67, +12.00]	人员重采样	0.814 / 0.819
16	73.33% [67.33, 79.33]	74.67% [68.67, 80.67]	-1.33 [-9.33, +7.33]	人员重采样	0.750 / 0.758
20	82.00% [76.00, 88.00]	80.67% [74.00, 86.67]	+1.33 [-7.33, +10.00]	人员重采样	0.782 / 0.766
24	82.00% [75.33, 88.67]	86.00% [80.00, 92.00]	-4.00 [-13.33, +5.33]	人员重采样	0.767 / 0.783
32	89.33% [83.33, 94.67]	92.00% [88.00, 95.33]	-2.67 [-9.33, +4.00]	人员重采样	0.886 / 0.899
48	92.00% [86.67, 96.67]	91.33% [86.00, 96.00]	+0.67 [-6.00, +8.00]	人员重采样	1.206 / 1.237
64	90.67% [86.00, 95.33]	96.67% [94.00, 99.33]	-6.00 [-11.33, -0.67]	人员重采样	1.569 / 1.686

每行每组：25人、50靶标、150次攻击、3个seed。人员重采样：10,000次bootstrap；边界法：零命中时使用Wilson有效样本量区间，差值使用Newcombe/MOVER。有效样本量为50/1.5≈33.33，不乘三个seed。

耗时是攻击调用时间，不等于GPU计费时间。全部主扫描攻击调用合计26.25小时；42个最终分片对应的调度计费下限为222.269 GPU小时。


D/C匹配平衡诊断

不属于 H1-H5 的统计检验；它检查两组在训练经历之外是否足够相似。

E17做什么？从未训练目标池中，为D选择同一字段、长度和参考难度尽量接近的C。匹配不要求字符串相同；匹配记录也不保证最终入选的两组已经平衡。这里检查的是实际攻击目标。

D/C 匹配平衡：SSN 点估计接近，email 仍有差异

点为 SMD，横线为 95% 区间；绿色带是平衡诊断参考，不是显著性检验。



实际攻击目标，每组每字段 25 个；正值表示 D 的该特征均值更大。此图不属于 H1-H5 检验。

字段	比较变量	SMD	95%区间	达标
ssn	字符数	0.000	[0.000, 0.000]	是
ssn	token数	-0.074	[-0.667, 0.465]	是
ssn	H 信息量	0.082	[-0.493, 0.643]	是
email	字符数	0.503	[-0.031, 1.098]	否
email	token数	0.613	[0.066, 1.315]	否
email	H 信息量	0.513	[-0.025, 1.103]	否

变量如何理解？字符数是字符串有多少个字符；token数是分词器把它切成多少块；H是参考模型认为这个字符串有多“意外”的信息量（bits），越大表示参考模型赋予它的概率越低，不是直接测得的攻击难度。


诊断结果： $SMD = (D \text{ 均值} - C \text{ 均值}) / \text{合并标准差}$ ，越接近0越相似。SSN三项点估计均满足预定 $|SMD| < 0.1$ ；email三项均未满足，且D邮箱平均更长、token更多、H更大。0.1是平衡诊断线，不是p值。

每字段25人/组。email不平衡限制H2/H3/H5的成员性解释；当前表不能算出它造成多少抽取率差异。H4只使用C，不依赖D/C匹配差值。

H1：提示容量增加，C是否更容易被生成？

当前数据支持总体上升趋势；局部点仍可能回落。

H1：提示容量增大时，未训练目标也更容易被生成



3 个 seed 是对同一批目标的重复攻击；不代表 3 次独立微调。区间为逐点 95% 区间。

实验前假设

零假设：C抽取率 α 与k无关，总体曲线为平。实验前预期： α 随k单调不降。这里考察C，不是D-C。

怎样判断

用Spearman相关系数 ρ 衡量排序趋势，接近+1表示强上升。按人员重新抽样并重复计算，所得95%区间完全大于0才通过。这个判据不能证明逐点单调。

结果

$\rho=0.9890$

95%区间 [0.9779, 0.9945]

每组25人中的C组、50目标、3个攻击seed。

是否符合预期？符合总体上升判据。例如C在k=20为80.67%，到k=64为96.67%；但k=32到48由92.00%降至91.33%。因此不能说每增加一个k都更高，更不能把总体趋势当成每个靶标必然单调。

对论文的意义与下一步：未参与微调的目标也会随攻击容量增加而更常被命中，因此“抽取成功”本身不足以归因于训练记忆。跨模型、其他攻击器能否复现这一趋势，需要另做实验。


原始 $p=0.000100$ ；Holm调整 $p=0.000400$ 。 p 衡量在零假设与计算模型成立时，出现当前或更极端统计结果的程度；它不是假设为真的概率。Holm用于控制H1-H4一起检验时的误报，四项并不因此成为同一个假设。

H2：有没有一个 k，让 C 成功率足够低？

原始1%要求尚未分辨：观察到0次成功，也不能确认总体成功率不超过1%。

H2：零次成功，仍不足以确认控制组上限 $\leq 1\%$

k=1-3：0/150 次成功；k=4：2/150 次成功 (1.33%)。



Wilson 使用假定的有效样本量；k=4 使用人员聚类 bootstrap。方法切换使区间宽度不可直接比较。因此，不能根据 k=4 的区间更窄就认定它比零命中点更安全。

实验前假设

存在某个 $k \geq 1$ ，使控制组真实成功率 α 不超过 1%。推广写法是 $\alpha \leq \epsilon$ ； ϵ 表示允许的 C 成功率上限，例如 1%、5% 或 9%。

预定判据

要求 α 的 95% 区间上界 $\leq \epsilon$ ，不能只看观察成功率。在“命中即判断为训练成员”的规则下，C 被误判的概率就是 α 。

结果与判定

k=1、2、3 均为 0/150 次命中；但保守区间上界仍为 10.33%，高于 1%。因此未确认 1% 条件，也未证明它不可能成立。

为什么图上 k=4 的上界反而较低？它观察到 2/150 次成功 (1.33%)，主分析用人员 bootstrap 得到上界 3.33%；零命中的 k=1-3 则换用保守 Wilson 区间，上界 10.33%。这是区间方法切换的结果，不能解释成 k=4 比零命中的点更安全。

对结果的影响：k=4 是否满足 5% 上限依赖区间方法。若也按同一 Wilson 约定计算，其上界为 12.60%。所以“5% 时有 k=4”只能作为当前表的条件性候选，不能当作已验证的可靠操作点。

设计预估约 9% 的分辨范围；按实际采用的保守区间，零命中上界为 10.33%，两者不是同一个数。下一步需要预先统一区间方法和所需精度，再增加独立控制人员。

H2：低 C 成功率之外，D 是否明显更高？

目前没有同时得到“C足够低”与“D明显高于C”支持的 k。

允许的C上限 ϵ	仅要求C的95%上界 $\leq \epsilon$ ：候选k	再要求D-C的95%下界 >0 ：候选k
1.00%	无	无
5.00%	4	无
9.00%	4	无
10.00%	4	无
15.00%	1、2、3、4	无
20.00%	1、2、3、4	无
30.00%	1、2、3、4	无
50.00%	1、2、3、4、6	无
75.00%	1、2、3、4、6、8、12	无
90.00%	1、2、3、4、6、8、12、16、20	无
100.00%	1、2、3、4、6、8、12、16、20、24、32、48、64	无

为什么加第二个条件？
如果D和C都很少成功，虽然C低，攻击也不一定
能区分训练成员。成员识别还需要D的成功率明显
高于C。

“明显高于”怎么读？
对差值 $\tau=D-C$ 计算95%区间；整个区间在0右边（
下界 >0 ）才支持D更高。区间跨0则方向未分辨。


与设计原文的关系
原文只要求“差值区间不含0”，没有限定正向。按
字面，在 $\epsilon=100\%$ 时 $k=64$ 也入选，但其D-C为
-6.00个百分点，方向相反。表中第三列明确展示
成员识别所需的正向条件。

表中k是当前混合区间规则下的描述性映射；5%、9%、10%行出现k=4的原因见上一页。100%上限几乎放弃控制误报，k=64的负差值也不能作为正向成员信号。

最终判定：1%条件未分辨；没有得到支持的正向联合操作点。设计未规定跨所有k如何做一个整体检验（“全局检验”），故不能宣称已正式证明“任何k都不存在”。H2没有有效p值，旧表中1只是占位。

H3：在论文原有的 k=20，能分辨 D 与 C 吗？

D=82.00%，C=80.67%；差值+1.33个百分点，但不确定区间仍跨过0。



区间包含 0：尚不能确认 D 的成功率更高；也不能据此认定两组等价或模型没有记忆。

实验前假设与意义

固定k=20，检验总体差值是否为0（双侧）。这是论文已有主点的校准，检验扣除C的forcing floor后还剩多少差异；它不是寻找最优k。

预定判据

D-C的95%人员bootstrap区间排除0，才拒绝“总体差值为0”。本次区间为[-7.33,+10.00]个百分点，包含0。

判定与新问题

尚不能分辨成员差异，也不能证明两组等效或模型没有记忆。后续应先定义多大的差异才有实际意义，再安排足够人员检验。

范围	每组人/靶标/seed	D及95%区间(%)	C及95%区间(%)	D-C及95%区间(百分点)
总体	25/50/3	82.00% [76.00, 88.00]	80.67% [74.00, 86.67]	+1.33 [-7.33, +10.00]
SSN (探索性)	25/25/3	64.00% [52.00, 76.00]	61.33% [48.00, 73.33]	+2.67 [-14.67, +20.00]
email (探索性)	25/25/3	100.00% [86.68, 100.00]	100.00% [86.68, 100.00]	+0.00 [-13.32, +13.32]

同一主扫描；k=20攻击耗时C/D=0.782/0.766小时。原始p=0.825617，Holm p=1.000000。email全部观察命中仍有总体不确定性；字段差异不能被总体平均掩盖。

三个seed的总体D/C分别为80%/78%、86%/86%、80%/78%（每个seed50次/组）。它们展示重复攻击波动，不增加独立人员数。

H4：先把“成正比”说清楚

假设是：目标信息量 H 翻倍，所需首次命中容量 $k_{\min}$ 也约翻倍。

实验前假设： $k_{\min}(t) \approx H(t) / \beta$ 。H4只使用控制组C，希望用一个固定的 β ，把目标信息量转换成需要的提示容量。

符号	含义
t	某一个具体目标字符串。
$H(t)$	参考模型给目标 t 的自信息量，单位bits；目标越不被参考模型预期， H 通常越大。
$k_{\min}(t)$	在本次正容量扫描中，三个固定攻击seed任一次首次成功时，最小的已观察 k 。
β (beta)	比例模型中的换算常数，单位bits/token：每个自由提示token对应多少目标信息量。

示意例子（不是实测数据）：若 $\beta=10$ bits/token， $H=40$ bits对应 $k_{\min} \approx 4$ ； $H=80$ bits对应 $k_{\min} \approx 8$ 。两者同时翻倍，这就是成正比。

为什么拟合里会出现斜率 γ ？把比例公式两边取对数：

$$\log(k_{\min}) \approx \log(H) - \log(\beta)$$

再允许数据自由决定斜率： $\log(k_{\min}) = a + \gamma \times \log(H) + \text{error}$ 。

新增符号的含义

$\log$ ：对数变换。

a ：直线截距。

γ (gamma)：对数坐标上的斜率。


error ： H 未解释的差异与攻击随机性。

比例关系要求 $\gamma=1$ ，且此时 $a=-\log(\beta)$ 。如果 γ 不等于1，就不能再从截距 a 报告一个通用的bits/token换算常数。 H 是参考模型的描述量，不是经验证的确定性容量下界。

H4：数据是否支持这条比例关系？

γ 的95%区间排除1；在当前工作模型下，简单比例关系不适合这些控制目标。

H4：当前拟合不支持 $k_{\min}$ 与 H 成正比



斜率怎样算出来？

对50个C目标，先记录每个目标的首次成功网格。例如在 $k=4$ 失败、 $k=6$ 首次成功，阈值工作模型将其记为(4,6]的区间信息。

用Weibull统计模型，寻找让这些区间观察最可能出现的参数（最大似然估计），得到 γ 。再按25名人员重抽样并重复拟合10,000次，得到95%区间。

预定判据

γ 的95%区间排除1，反驳简单比例形式。这里检验 γ 是否为1，不是检验它是否为0。

结果： $\gamma=3.484486$ ，95%区间[2.811469, 4.209360]；原始 $p=0.000100$ ，Holm $p=0.000400$ 。区间整体高于1，未满足成正比的要求。

这一判定有何限制？控制组7/50个靶标在首次成功后，于某个更大的 k 又全部失败。也就是说，“失败→成功→失败”真实存在；首次命中不是确定的能力门槛，(4,6]只是阈值模型的解释。本次没有到64仍未命中的控制目标。


对论文与下一步：不能据此给出一个可迁移的通用 β 。需要进一步检查字段差异、攻击随机性和非线性关系；这些是新研究方向，不能把 $\gamma \approx 3.48$ 当成已经建立的新普遍定律。

“工作模型”是这次估计使用的统计近似，并非物理定律。本页沿用当前主分析的“三个seed首次任一命中”口径；Weibull工作分布及 p 算法为重分析中披露的实现约定，不能追溯称为事前固定。

H5 : D-C 的差值会在中间容量达到峰值吗？

k=4和12是当前并列最高点，但尚未定位一个稳定、可靠的最优容量。

H5 (探索性) : 观察到的峰值不足以确定最佳 k



橙色菱形: k=4 和 12 并列最高, 均为 +2.67 个百分点; 竖线: τ 的逐点 95% 区间。
绿色括号描述峰可能出现的 k 位置, 和纵轴差值的区间含义不同; 不能确认稳定的内部峰。

实验前假设

预期差值 τ 随k先升后降, 在1与64之间出现内部峰; 对照是单调或平坦关系。H5研究D-C的峰, 不是D或C自身成功率的峰。

为什么叫探索性?

实验前就判断当前人数不足以可靠识别峰形, 因此H5只用于提出后续问题, 不作为确认性发现, 也不参加H1-H4的Holm校正。

预定判断思路

重复抽样看最高点落在哪里, 其95%位置包络应避开两端; 同时用弯曲方向检查是否确有“先升后降”。重分析保留所有并列最高点。

观察结果: k=4、12并列+2.67个百分点, 但各自差值区间均跨0。峰位置的95%包络为[4,48], 范围很宽; 它表示最高点位置的不确定性, 不表示此区间内所有k都好。

是否符合假设? 位置条件在字面上通过。b是拟合曲线的弯曲系数, 负值表示向下弯; 本次 $b=-0.00391$, 95%区间 $[-0.01660, 0.00956]$ 含0, 未支持明确的峰形。探索性单侧 $p=0.2810$, 整体仍不确定。

下一步: 先规定峰值至少应高出两侧多少, 再增加独立人员并加密候选容量。当前不能宣称k=4或12最优, 也不能因证据不足就宣称曲线平坦。b仅是对 $\log(k)$ 拟合二次曲线的弯曲系数。

如何使用这份汇报

本文件完整呈现所选结果；数值重算已完成，研究的正式验收仍未通过。

目前可以汇报什么？已保存的42个Cheaha主分片覆盖完整14个k与3个攻击seed，共4,200次攻击；本文件中的曲线、字段计数与逐靶标矩阵逐格对应。D/C比较来自同一模型、同一攻击流程下的不同目标组。

为什么仍称“条件性结果”？现有攻击数据可以复算，但仍缺当时执行模型的指纹与各分片的完整启动绑定，6个分片的历史代码清洁性未知；部分失败/重试归属及Colab历史时间也未补齐。email匹配未过关，H2跨k整体检验也未预先定义。

哪些结论不能从这里推出？不能把攻击命中直接叫作训练记忆；不能把未显著叫作两组相同；不能把一次首次成功叫作确定门槛；也不能把探索性的候选k作为部署选择。结论范围限于本次模型、两种合成字段及攻击预算。

成本口径

C攻击调用13.022小时；D为13.229小时。主分片调度计费合计至少222.269 GPU小时，包含调用之外的占用；两种计时不能混为一谈。

数据与文档索引

以下路径均相对本研究目录；Markdown版提供可点击链接。所有图沿用纠错重分析数值，没有新增模型实验。

可核对内容	文件
完整分析与限制	analysis.md
实验前假设与执行方案	design.md；protocol.md
权威数值	results.json → reanalysis.estimateds
全部曲线与区间	reanalysis/curve_table.csv
完整抽取率与计数	reanalysis/extraction_rates_and_counts_full.csv
字段计数与唯一靶标数	reanalysis/extraction_counts_by_field_full.csv
完整匿名靶标矩阵	reanalysis/target_success_by_k_full.csv
实际攻击目标平衡	reanalysis/actual_balance.csv
首次命中与模型输入	reanalysis/kmin_recomputed.csv
复算方法与独立核对	reanalysis/method_choices.md；reanalysis/statistics_review.md

本汇报保留总体曲线、字段/靶标描述、匹配诊断及H1-H5。字段拆分和H5均明确标注探索性；未把原先删除的连续评分分析重新加入。